

Optimización de portafolio en el IPSA: ¿Una estrategia sofisticada le gana al 1/N?

Carlos Tapia Mauricio Pizarro Brian Valenzuela

INF398 — Introducción al Aprendizaje Automático

2 de julio de 2026

1 Objetivo y enfoque

Construimos estrategias de inversión relativamente sofisticadas para un portafolio de acciones del IPSA y las pusimos a prueba contra dos referencias simples. La pregunta no es sólo cuál rinde más, sino si las diferencias observadas son **estadísticamente robustas o apenas ruido** del período analizado. El objetivo no es demostrar que el *Machine Learning* (ML) gana: si no mejora al benchmark, ese resultado es igual de válido y lo reportamos como tal.

Exploramos dos familias de modelos ML. La primera **predice el retorno esperado** μ de cada acción y entrega ese vector a un optimizador de cartera (Ridge, Lasso, Elastic Net y un MLP). La segunda es un **MLP de asignación directa** (*decision-focused learning*, DFL): en lugar de predecir retornos, la red produce directamente los pesos del portafolio, entrenada para maximizar el Sharpe. La idea de esta segunda familia es saltarse el paso intermedio de predecir μ y optimizar la métrica que realmente importa.

Sobre esa base, la estrategia combina cinco ingredientes:

- **Predicción de retornos con ML**, con la regularización elegida sin mirar el futuro.
- **Covarianza robusta** mediante *shrinkage* de Ledoit–Wolf, que estabiliza la matriz de riesgo cuando hay pocos datos.
- **Validación walk-forward**: en cada mes se estiman los parámetros con datos pasados y se aplican al mes siguiente, sin acceso a información futura.
- **Costos de transacción** de 0.1% por rebalanceo.
- **Restricciones de concentración**: pesos acotados por acción, para no depender de una sola apuesta.

Las comparamos contra dos benchmarks: el reparto ingenuo 1/N (pesos iguales) y el Markowitz histórico de máximo Sharpe. Adelantamos el resultado central: **algunas métricas mejoran marginalmente sobre el 1/N, pero esas mejoras no resisten un test de significancia**, y el 1/N permanece extremadamente competitivo.

2 Datos y metodología

Universo y datos. Trabajamos con 21 acciones del IPSA con historia disponible desde 2008, sobre retornos mensuales. Los precios de cierre ajustados se descargan de Yahoo Finance; se descartan acciones con demasiados datos faltantes y se recortan retornos extremos ($\pm 40\%$ mensual) para tratar *outliers*. Se obtienen 203 meses de retornos (feb. 2008–dic. 2024).

Features sin mirar el futuro. Para cada acción construimos 9 *features* a partir de sus propios retornos (momentum a 1/3/6/12 meses, volatilidad a 3 y 6 meses, media móvil, desviación respecto de esa media y un RSI). Todas van rezagadas un mes: en el mes t sólo se usa información disponible hasta $t-1$, y el objetivo a predecir es el retorno de t . La matriz final es de 191 meses $\times$ 189 columnas (9 por acción). La evaluación es **walk-forward**: en cada mes se estiman los parámetros con los 36 meses previos y se aplican al mes siguiente. Así el modelo nunca ve el dato que intenta predecir,

siendo una forma honesta de medir su desempeño. El período de test resultante es de **155 meses** (feb. 2012–dic. 2024).

Las seis estrategias. Comparamos: (1) el reparto ingenuo $1/N$; (2) Markowitz clásico (μ histórico y covarianza muestral); (3) Markowitz con covarianza Ledoit–Wolf; (4) mínima varianza con Ledoit–Wolf, que *no* usa retornos esperados; (5) el ML Ridge, que predice μ y lo entrega al optimizador de máximo Sharpe; y (6) el DFL, el MLP que asigna pesos directamente. En todos los casos que optimizan, la covarianza se estabiliza con *shrinkage* de Ledoit–Wolf y los pesos se obtienen resolviendo un problema convexo (*cvxpy*) con suma 1 y cotas por acción $[0, 0.20]$. Se descuentan costos de 0.1% por rebalanceo.

Cómo elegimos los hiperparámetros: MSE vs. Sharpe. En la línea base, los modelos que predicen μ eligen su regularización minimizando el error de predicción (MSE), acción por acción. Como variante, probamos elegirla optimizando directamente el **Sharpe** de la cartera sobre un tramo de validación interno a la ventana (los últimos 12 meses), sin tocar nunca el período de test. Esto responde una duda natural: ¿y si afinamos el modelo para la métrica que de verdad nos importa, en vez del error de predicción? La respuesta, adelantamos, es que no ayuda.

Test de significancia. Para decidir si las diferencias de Sharpe son reales o ruido, usamos un *bootstrap* por bloques sobre los retornos fuera de muestra (5000 réplicas, bloques de 6 meses, remuestreo pareado). De ahí obtenemos, para cada estrategia, el intervalo de confianza al 95% de su Sharpe y el p -valor de la diferencia contra el $1/N$.

3 Resultados

La Figura 1 resume el universo: precios normalizados, retorno mensual promedio, volatilidad anualizada por acción y matriz de correlaciones. Destaca la fuerte dispersión de volatilidades, desde niveles en torno al 22% en las acciones más defensivas hasta sobre 40% en las mineras (CAP, SQM-B), y las correlaciones mayormente moderadas, salvo pares ligados por control común, como Copec–AntarChile.




Figura 1: Análisis exploratorio del universo de 21 acciones del IPSA (2008–2024).

Desempeño de las estrategias. El Cuadro 1 muestra el desempeño de las seis estrategias y la Figura 2 su evolución. En retorno y Sharpe, el ML Ridge encabeza la tabla (Sharpe 0.296) y el 1/N queda en el medio (0.125). Pero el patrón importante aparece en las columnas de riesgo: la mínima varianza logra la menor volatilidad (13.7%) y el menor *drawdown* (−33.6%). En el otro extremo, el DFL —pese a estar diseñado para optimizar el Sharpe de forma directa— queda *último*, con un Sharpe *negativo* (−0.040) y un *turnover* desproporcionado (1.12 frente a 0.045 del 1/N). Ese exceso de rotación es la primera señal de un modelo que se sobreajusta a la ventana de entrenamiento.

Cuadro 1: Métricas de desempeño en el walk-forward (155 meses, 2012–2024).

Estrategia	Ret. acum.	CAGR	Vol. anual	Sharpe	Max DD	Turnover
1/N (Equal-Weight)	109.5%	5.9%	15.8%	0.125	−40.7%	0.045
Markowitz clásico	164.6%	7.8%	15.7%	0.240	−37.9%	0.280
Markowitz + Ledoit–Wolf	163.8%	7.8%	15.8%	0.238	−38.9%	0.275
Mínima Varianza + LW	94.6%	5.3%	13.7%	0.080	− 33.6%	0.141
ML Ridge + LW	200.8%	8.9%	16.6%	0.296	−38.0%	0.677
DFL (MLP directo)	50.1%	3.2%	15.8%	−0.040	−39.8%	1.117

Backtest - Estrategias de Portafolio IPSA



Figura 2: Comparación de las seis estrategias: valor acumulado, *drawdowns*, rolling Sharpe, distribución de retornos y evolución del *shrinkage* de Ledoit–Wolf.

El predictor de retornos no tiene señal. El poder predictivo se mide con la R^2_{oos} : si es positiva, el modelo predice mejor que usar la media histórica; si es negativa, predice *peor*. La R^2_{oos} del Ridge es -0.085 (con un *Information Coefficient* $IC = +0.008$, prácticamente cero): el modelo no aporta información sobre los retornos futuros. El contraste con su R^2_{oos} *in-sample* ($+0.097$, positiva) es la firma de que hay sobreajuste: aprende muy bien el pasado y no generaliza nada. El Cuadro 2 y la Figura 3 confirman que esto **no depende del modelo**: ninguno de los cuatro —lineales o MLP— logra R^2_{oos} positiva. Por lo tanto, el aparente buen Sharpe del ML+LW (0.296) no viene de acertarle a los retornos, sino del optimizador y de la covarianza.

Cuadro 2: Comparación de modelos ML (hiperparámetros por MSE). Sharpe del $1/N = 0.125$.

Modelo	R^2_{oos}	IC	MSE	Sharpe _{ML}	vs. $1/N$
Ridge	-0.085	+0.008	0.00661	0.296	+0.171
Lasso	-0.037	+0.022	0.00632	0.267	+0.142
Elastic Net	-0.042	+0.022	0.00634	0.247	+0.122
MLP	-0.054	-0.013	0.00642	0.198	+0.073




Figura 3: Poder predictivo (R^2_{oos}) y Sharpe de la cartera ML+LW por modelo. Ningún modelo alcanza R^2_{oos} positiva.

Afinar directamente por Sharpe no rescata el resultado. El Cuadro 3 repite el ejercicio, pero eligiendo la regularización por Sharpe en validación interna. La R^2_{oos} sigue negativa (de hecho empeora, porque el criterio ya no busca predecir bien) y el Sharpe del mejor modelo apenas llega a 0.160. Esto no es contradictorio, ya que al no haber señal, el Sharpe de validación —calculado sobre 12 meses— es esencialmente ruido, y afinar un parámetro para maximizar ruido no mejora nada fuera de muestra. La evidencia más clara está en *qué* regularización se elige: para el mejor modelo afinado (Lasso), el α no converge a un valor, sino que se reparte a lo largo de los 155 meses ($\alpha = 0.1$ en 79 meses, $\alpha = 0.01$ en 38 y $\alpha = 0.001$ en 38). Si existiera una señal estable, la selección convergería a un valor; que no lo haga confirma que no hay nada estable que optimizar. El DFL replica el patrón: su Sharpe es -0.040 , por debajo del $1/N$.

Cuadro 3: Modelos ML con hiperparámetros elegidos por Sharpe (validación interna, sin fuga).

Modelo	R^2_{oos}	IC	Sharpe _{ML}	vs. $1/N$
Ridge	-0.251	-0.006	0.150	+0.025
Lasso	-0.113	+0.017	0.160	+0.035
Elastic Net	-0.106	+0.003	0.044	-0.081

Ninguna diferencia es significativa. El *bootstrap* por bloques confirma lo anterior (Cuadro 4 y Figura 4). Los intervalos de confianza al 95% de los seis Sharpe **incluyen el cero**, así que ninguna estrategia tiene siquiera un Sharpe distinguible de cero. Y ninguna supera al $1/N$ de forma significativa: todos los $p \geq 0.23$. El mejor candidato, el ML+LW, da $p = 0.234$; el mejor ML afinado por Sharpe (Lasso), $p = 0.831$. Dicho de otro modo, con este período de datos no podemos afirmar que ninguna estrategia le gane al reparto ingenuo.

Cuadro 4: Bootstrap del Sharpe: estimación, intervalo de confianza 95% y p -valor de la diferencia contra $1/N$.

Estrategia	Sharpe	IC 95%	p vs. $1/N$
$1/N$ (Equal-Weight)	0.125	$[-0.376, +0.581]$	—
Markowitz clásico	0.240	$[-0.308, +0.738]$	0.536
Markowitz + Ledoit–Wolf	0.238	$[-0.310, +0.740]$	0.512
Mínima Varianza + LW	0.080	$[-0.453, +0.554]$	0.626
ML Ridge + LW	0.296	$[-0.219, +0.773]$	0.234
DFL (MLP directo)	-0.040	$[-0.578, +0.462]$	0.324




Figura 4: Sharpe anualizado con intervalos de confianza bootstrap. Todos los intervalos cruzan el cero (línea punteada): ninguna estrategia es estadísticamente superior.

4 Discusión

El resultado principal es que **ninguna de las estrategias optimizadas supera al $1/N$ de manera estadísticamente distinguible**. Las mejoras de Sharpe son marginales y se evaporan al cuantificar su incertidumbre: con 155 meses de test, el error de estimación del Sharpe es tan grande que las diferencias observadas son indistinguibles del azar.

Lejos de ser anómalo, esto reproduce el hallazgo central de DeMiguel, Garlappi y Uppal (2009). Al comparar 14 modelos de optimización de portafolio contra el reparto ingenuo $1/N$ en múltiples conjuntos de datos, esos autores encontraron que ninguno lo superaba de forma consistente fuera de muestra. La causa es el **error de estimación de los parámetros** —sobre todo de los retornos esperados μ —, que el optimizador de Markowitz amplifica en lugar de corregir. El $1/N$, al no estimar nada, no sufre ese error. Nuestro experimento confirma el mecanismo de forma directa: μ no es predecible en esta muestra (ni con la media histórica ni con ningún modelo ML, cuya R^2_{oos} es negativa en todos los casos), de modo que optimizar en base a μ no puede agregar valor.

El caso del DFL es ilustrativo por sí solo. Una arquitectura diseñada para maximizar el Sharpe de forma directa termina siendo la peor estrategia en Sharpe (incluso negativo) y con el mayor *turnover*. Es exactamente el sobreajuste que cabía esperar: al maximizar el Sharpe *in-sample* de una ventana corta, la red persigue patrones que no se repiten fuera de muestra.

La única dimensión donde sí aparece una diferencia consistente —aunque no en Sharpe— es el **riesgo**. La mínima varianza, que ignora por completo μ , entrega la menor volatilidad y el menor *drawdown*. Para un inversionista cuyo objetivo es controlar el riesgo, es preferible; no porque “gane” en términos ajustados por riesgo, sino porque obtiene un Sharpe equivalente con caídas más suaves.

5 Conclusión

Construimos y evaluamos, de forma honesta y fuera de muestra, dos familias de modelos ML para asignar un portafolio del IPSA —modelos que predicen μ y un MLP de asignación directa—, con covarianza robusta, validación sin fuga de información, costos y restricciones de concentración. A pesar de esa sofisticación, no encontramos evidencia de que superen al 1/N en Sharpe: todas las R^2_{oos} son negativas y ninguna estrategia es estadísticamente distinguible del reparto ingenuo. El valor del trabajo es metodológico: una evaluación walk-forward sin fuga, la medición explícita del poder predictivo fuera de muestra y un test de significancia que evita confundir ruido con habilidad. El cierre defendible es que, con los datos y *features* disponibles, ni la predicción de retornos ni la asignación directa por ML le ganan al 1/N, y la única ventaja real —en riesgo— la ofrece una estrategia que ni siquiera intenta predecir retornos.

6 Limitaciones

- **Sesgo de supervivencia.** El universo incluye sólo acciones que siguen listadas y líquidas hoy, lo que infla levemente todos los resultados.
- **Poder estadístico.** Con 155 meses de test, el error de estimación del Sharpe es grande para magnitudes tan pequeñas; los intervalos de confianza son anchos por construcción.
- **Features.** Se limitan a momentum y volatilidad; no se exploran señales fundamentales ni macroeconómicas (p. ej. precio del cobre o USD/CLP).
- **Sobreajuste del DFL.** La red de asignación directa maximiza el Sharpe *in-sample* de una ventana corta; pese a la regularización, el criterio es intrínsecamente propenso a sobreajustar, como confirma su desempeño.
- **Reproducibilidad.** Los precios se descargan en vivo de Yahoo Finance, que revisa sus históricos; por eso los números pueden variar entre corridas. Conviene cachear los precios a CSV para fijar los resultados del informe.

7 Apéndice: fórmulas de las métricas

Esta sección deja registro de cómo se calculó cada medida y, sobre todo, de cómo interpretarla. Notación: r_t es el retorno mensual de la cartera en el mes t (ya descontados los costos), r_f la tasa libre de riesgo mensual, $\bar{x}$ el promedio de una cantidad x sobre los $T = 155$ meses de test y $\hat{\sigma}$ la desviación estándar muestral. El retorno neto de un mes es el retorno bruto de la cartera menos lo que cuesta rebalancearla:

$$r_t = \underbrace{\mathbf{w}_t^\top \mathbf{r}_t}_{\text{retorno bruto}} - \underbrace{c \sum_i |w_{i,t} - w_{i,t}^-|}_{\text{costo de mover la cartera}}, \quad c = 0.1\%,$$

donde $w_{i,t}^-$ es el peso de la acción i justo antes de rebalancear.

Métricas de desempeño

Sharpe. Mide cuánto retorno se obtiene por cada unidad de riesgo. Toma el retorno promedio por sobre la tasa libre de riesgo y lo divide por su volatilidad:

$$\text{Sharpe} = \frac{\overline{r - r_f}}{\hat{\sigma}_{r - r_f}} \sqrt{12}.$$

Cuanto más alto, mejor. El factor $\sqrt{12}$ lo lleva de escala mensual a anual. A grandes rasgos, un Sharpe de 0.1 dice que el retorno anual en exceso equivale a una décima de la volatilidad anual.

Sortino. Es un Sharpe que sólo castiga la volatilidad “mala”. En lugar de la desviación total usa la *desviación a la baja* DD, que ignora los meses buenos:

$$\text{Sortino} = \frac{\overline{r - r_f}}{\text{DD}} \sqrt{12}, \quad \text{DD} = \sqrt{\frac{1}{T} \sum_{t=1}^T [\min(r_t - r_f, 0)]^2}.$$

El $\min(\cdot, 0)$ deja pasar sólo los meses en que el retorno cayó bajo r_f ; los meses positivos entran como cero. Se divide por el total de meses T (no sólo por los negativos), de modo que la métrica refleja el *tamaño* de las caídas y no cuántas hubo.

Volatilidad anual y CAGR. La primera es la dispersión de los retornos; la segunda, la tasa de crecimiento anual compuesta que, aplicada constante, reproduce el resultado final:

$$\sigma_{\text{anual}} = \hat{\sigma}_r \sqrt{12}, \quad \text{CAGR} = \left(\prod_{t=1}^T (1 + r_t) \right)^{12/T} - 1.$$

El producto $\prod_t (1 + r_t)$ es cuánto crece un peso invertido a lo largo del test; el exponente $12/T$ convierte ese crecimiento total en un equivalente por año.

Máximo drawdown y Calmar. El *drawdown* de un mes es cuánto ha caído la cartera desde su punto más alto previo; el máximo *drawdown* es la peor de esas caídas. Con $V_t = \prod_{s \leq t} (1 + r_s)$ el valor acumulado:

$$\text{MaxDD} = \min_t \frac{V_t - \max_{s \leq t} V_s}{\max_{s \leq t} V_s}, \quad \text{Calmar} = \frac{\text{CAGR}}{|\text{MaxDD}|}.$$

$\max_{s \leq t} V_s$ es el máximo histórico hasta t , y la fracción mide qué tan por debajo del máximo se está. El Calmar relaciona el crecimiento anual con esa peor caída.

Turnover. Cuánto se reordena la cartera en cada rebalanceo, sumando los cambios de peso de todas las acciones y promediando sobre los R rebalanceos:

$$\text{Turnover} = \frac{1}{R} \sum_{t \in \text{rebal}} \sum_i |w_{i,t} - w_{i,t}^-|.$$

Un valor alto implica mucha rotación (y más costos): el 1.12 del DFL frente a 0.045 del $1/N$ indica que el DFL rehace casi por completo la cartera cada mes.

Cuán bien predice el modelo

R^2 fuera de muestra e IC. Sobre todos los pares (acción, mes) del período de test, con r el retorno realizado y $\hat{\mu}$ la predicción:

$$R_{\text{os}}^2 = 1 - \frac{\sum (r - \hat{\mu})^2}{\sum (r - \bar{r})^2}, \quad \text{IC} = \text{corr}(\hat{\mu}, r).$$

El R_{os}^2 compara dos errores: el del modelo (numerador) contra el de “predecir siempre el promedio” $\bar{r}$ (denominador). Si el modelo le gana al promedio, la fracción es menor que 1 y $R_{\text{os}}^2 > 0$; si es peor, la fracción supera 1 y $R_{\text{os}}^2 < 0$ —justo nuestro caso, que indica ausencia de señal. El R_{in}^2 es la misma fórmula, pero medida dentro de la ventana de entrenamiento (promediada sobre acciones y ventanas); que sea positivo mientras el de fuera de muestra es negativo es la señal clásica de sobreajuste. El IC (*Information Coefficient*) es la correlación de Pearson entre lo predicho y lo realizado: un valor cercano a 0 significa que la predicción no se relaciona con lo que efectivamente pasó.

Optimización de cartera

Los pesos salen de un optimizador que usa la covarianza Σ estabilizada con *shrinkage* de Ledoit–Wolf,

$$\hat{\Sigma}_{\text{LW}} = (1 - \delta) \mathbf{S} + \delta \mathbf{F},$$

una mezcla entre la covarianza muestral $\mathbf{S}$ (precisa pero ruidosa con pocos datos) y un objetivo estructurado y estable $\mathbf{F}$; la intensidad $\delta \in [0, 1]$ se elige de forma automática. Con esa Σ , cada estrategia resuelve uno de dos problemas:

$$\text{máx. Sharpe: } \max_{\mathbf{w}} \frac{\mathbf{w}^\top (\boldsymbol{\mu} - r_f \mathbf{1})}{\sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}},$$

$$\text{mín. varianza: } \min_{\mathbf{w}} \mathbf{w}^\top \Sigma \mathbf{w},$$

ambos con $\sum_i w_i = 1$ (todo el capital invertido) y $0 \leq w_i \leq 0.20$ (sin ventas en corto y con tope de 20% por acción). En el máximo Sharpe, el numerador es el retorno esperado de la cartera y el denominador su volatilidad. La mínima varianza minimiza sólo esa volatilidad y ni siquiera mira $\boldsymbol{\mu}$, por lo que es inmune al error de estimar los retornos esperados.

Markowitz (clásico y +Ledoit–Wolf). No hay modelo predictivo: el retorno esperado de cada acción es simplemente su promedio histórico dentro de la ventana, $\hat{\mu}_i = \bar{r}_{i, \text{ventana}}$, y la covarianza es la muestral $\mathbf{S}$ (clásico) o su versión con *shrinkage* $\hat{\Sigma}_{\text{LW}}$ (+Ledoit–Wolf). Con eso resuelve el problema de máximo Sharpe ya visto:

$$\max_{\mathbf{w}} \frac{\mathbf{w}^\top (\hat{\boldsymbol{\mu}} - r_f \mathbf{1})}{\sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}}, \quad \text{s.a. } \sum_i w_i = 1, \quad 0 \leq w_i \leq 0.20.$$

Ridge. Para cada acción i ajusta coeficientes β_i que predicen su retorno a partir de las *features*, penalizando la magnitud *cuadrática* de los coeficientes:

$$\hat{\boldsymbol{\beta}}_i^{\text{Ridge}} = \arg \min_{\boldsymbol{\beta}} \sum_t (r_{i,t} - \mathbf{x}_{i,t-1}^\top \boldsymbol{\beta})^2 + \alpha \sum_j \beta_j^2.$$

La penalización L_2 ($\alpha \sum_j \beta_j^2$) achica todos los coeficientes hacia cero de forma proporcional, sin anular ninguno. Mientras más grande α , más se “aplana” el modelo hacia predecir la media: la validación cruzada elige un α alto porque no hay señal que valga la pena capturar.

ML Ridge + LW. Es el ensamble de las dos piezas anteriores: la predicción de Ridge entra como $\hat{\boldsymbol{\mu}}$ al optimizador de máximo Sharpe, usando la covarianza con *shrinkage* de Ledoit–Wolf. Para cada mes t del test:

$$\begin{aligned} \hat{\mu}_i &= \mathbf{x}_{i,t-1}^\top \hat{\boldsymbol{\beta}}_i^{\text{Ridge}} \quad \text{para cada acción } i, \\ \mathbf{w}_t &= \arg \max_{\mathbf{w}} \frac{\mathbf{w}^\top (\hat{\boldsymbol{\mu}} - r_f \mathbf{1})}{\sqrt{\mathbf{w}^\top \hat{\Sigma}_{\text{LW}} \mathbf{w}}}, \quad \text{s.a. } \sum_i w_i = 1, \quad 0 \leq w_i \leq 0.20. \end{aligned}$$

Es decir, $\hat{\boldsymbol{\mu}}$ ya no es el promedio histórico (como en Markowitz), sino la predicción de Ridge; la covarianza $\hat{\Sigma}_{\text{LW}}$ es la misma que usa “Markowitz + Ledoit–Wolf”.

Lasso. Misma idea que Ridge, cambiando la penalización cuadrática por una en valor absoluto:

$$\hat{\boldsymbol{\beta}}_i^{\text{Lasso}} = \arg \min_{\boldsymbol{\beta}} \sum_t (r_{i,t} - \mathbf{x}_{i,t-1}^\top \boldsymbol{\beta})^2 + \alpha \sum_j |\beta_j|.$$

La penalización L_1 puede llevar coeficientes exactamente a **cero**, no sólo achicarlos: hace selección automática de *features*, mientras que Ridge las mantiene todas (aunque pequeñas).

Elastic Net. Combina ambas penalizaciones con un parámetro de mezcla $\rho \in [0, 1]$:

$$\hat{\beta}_i^{\text{EN}} = \arg \min_{\beta} \sum_t (r_{i,t} - \mathbf{x}_{i,t-1}^\top \beta)^2 + \alpha \left[\rho \sum_j |\beta_j| + \frac{1-\rho}{2} \sum_j \beta_j^2 \right].$$

Con $\rho = 1$ es Lasso puro; con $\rho = 0$, Ridge puro. Es útil cuando hay *features* muy correlacionadas entre sí –como ocurre con nuestras 9 *features*, varias de las cuales miden variantes de lo mismo–: Lasso puro tiende a elegir una del grupo casi al azar y descartar el resto, mientras Elastic Net las reparte de forma más estable.

En los tres modelos anteriores, α (y ρ para Elastic Net) se elige por validación cruzada *dentro* de la ventana de entrenamiento, sin tocar el mes a predecir. El retorno esperado resultante es $\hat{\mu}_i = \mathbf{x}_{i,t-1}^\top \hat{\beta}_i$, y ese vector $\hat{\mu}$ es el que recibe el optimizador de máximo Sharpe (con covarianza Ledoit–Wolf) para obtener los pesos finales.

El modelo MLP de asignación directa (*decision-focused learning*). Aquí no hay paso intermedio de predecir μ : una red f_θ toma las *features* de todas las acciones y entrega directamente los pesos de la cartera,

$$\mathbf{w}_t = \text{softmax}(f_\theta(\mathbf{X}_{t-1})),$$

(o una capa de salida equivalente que garantice $\sum_i w_i = 1$, $w_i \geq 0$), entrenada minimizando el negativo del Sharpe de la cartera resultante sobre la ventana de entrenamiento:

$$\theta^* = \arg \min_{\theta} - \text{Sharpe}(\{\mathbf{w}_t^\top \mathbf{r}_t\}_{t \in \text{train}}).$$

La diferencia de fondo con Ridge (u otros modelos que predicen μ) más Markowitz: ahí se optimizan dos objetivos en dos pasos separados –primero minimizar el error de predicción, después maximizar el Sharpe dado $\hat{\mu}$ –; acá se optimiza un único objetivo de punta a punta (de ahí el nombre *decision-focused*: la red aprende directamente para la decisión final, no para un paso intermedio).

Test de significancia (bootstrap por bloques)

Para saber si una diferencia de Sharpe es real o suerte del período, remuestreemos la historia muchas veces y observamos cuánto varía el resultado. En cada una de las 5000 réplicas se arma una serie “alternativa” pegando bloques contiguos de $L = 6$ meses tomados al azar y se recalcula el Sharpe. Los mismos bloques se aplican a todas las estrategias (remuestreo pareado), de modo que la comparación es justa. El intervalo de confianza al 95% son los percentiles 2.5 y 97.5 de esos 5000 Sharpe. Para comparar una estrategia contra el $1/N$ miramos, en cada réplica, la diferencia $d^* = \text{Sharpe}_{\text{estr}}^* - \text{Sharpe}_{1/N}^*$, y el p -valor a dos colas es

$$p = 2 \min \{ \Pr(d^* \leq 0), \Pr(d^* \geq 0) \}.$$

Un p grande, como los que obtuvimos, significa que la diferencia observada cabe cómodamente dentro de lo que produce el puro azar: no es distinguible de cero.

Referencia. DeMiguel, V., Garlappi, L., & Uppal, R. (2009). *Optimal Versus Naive Diversification: How Inefficient Is the 1/N Portfolio Strategy?* Review of Financial Studies, 22(5), 1915–1953.