

¿Puede el *Machine Learning* mejorar un portafolio del IPSA?

Modelos predictivos y de asignación directa frente al 1/N

Carlos Tapia Mauricio Pizarro Brian Valenzuela

INF398 — Introducción al Aprendizaje Automático

- El proceso de predicción para la inversión
- Algoritmo clásico vs. algoritmo propuesto
- Cómo funciona el algoritmo propuesto
- Optimización de los modelos ML
- Comparación entre modelos
- Bootstrap y conclusión

El proceso de predicción para la inversión

Aspectos técnicos

- Sharpe: Mide cuánto retorno se obtiene por cada unidad de riesgo:

$$\text{Sharpe} = \frac{\overline{r - r_f}}{\hat{\sigma}_{r - r_f}} \sqrt{12}.$$

Cuanto más alto mejor.

- R_{oos}^2 e IC: Sobre todos los pares (acción, mes) del período de test, con r el retorno realizado y $\hat{\mu}$ la predicción:

$$R_{\text{oos}}^2 = 1 - \frac{\sum (r - \hat{\mu})^2}{\sum (r - \bar{r})^2}, \quad \text{IC} = \text{corr}(\hat{\mu}, r).$$

- Retorno mensual:

$$r_t = \underbrace{w_t^\top r_t}_{\text{retorno bruto}} - \underbrace{c \sum_i |w_{i,t} - w_{i,t}^-|}_{\text{costo de mover la cartera}}, \quad c = 0.1\%,$$

donde $w_{i,t}^-$ es el peso de la acción i justo antes de rebalancear.

El problema

Gestión de portafolio: distribuir el capital entre N acciones para maximizar el **retorno ajustado por riesgo** (Sharpe).



- **Universo:** 21 acciones del IPSA (Yahoo Finance), con retornos *mensuales* 2008–2024.
- **Features** (por acción): momentum (1/3/6/12 m), volatilidad *rolling*, media móvil, RSI.
- **Lo que entrega un modelo:** una estimación del **retorno esperado** $\hat{\mu}_i$ de cada acción $\Rightarrow$ insumo para decidir los pesos.

Evaluación walk-forward

En cada mes se entrena con los 36 meses previos y se predice el siguiente. Período de test: 155 meses (2012–2024).

El universo: análisis exploratorio



Analisis Exploratorio - Acciones IPSA



Precios del mercado chileno y retorno mensual promedio por acción.

El universo: análisis exploratorio

Analisis Exploratorio - Acciones IPSA



Volatilidades dispersas: desde $\sim 22\%$ en las defensivas hasta sobre 40% en las mineras (CAP, SQM-B); correlaciones mayormente moderadas.

Algoritmo clásico vs. algoritmo propuesto

Markowitz clásico

Dado μ (retornos esperados) y Σ (covarianza), busca los pesos de máximo Sharpe:

$$\max_w \frac{w^\top \mu - r_f}{\sqrt{w^\top \Sigma w}} \quad \text{s.a.} \quad 1^\top w = 1, \quad 0 \leq w_i \leq 0.2$$

En la versión **clásica** ambos insumos salen de los datos históricos:

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T r_t \quad (\text{media histórica}), \quad \hat{\Sigma} = \text{covarianza muestral.}$$

Punto débil

$\hat{\mu}$ es difícil de estimar y el optimizador **amplifica** ese error.

Algoritmo propuesto: ML + Markowitz

Misma optimización, pero mejores insumos:

- $\hat{\mu}_i = f_{\theta}(x_i)$ — un modelo **ML** predice el retorno esperado desde las features.
- $\hat{\Sigma} = (1 - \delta) S + \delta F$ — covarianza con *shrinkage* de Ledoit–Wolf (más estable).¹

Modelos de predicción de μ :

- Ridge
- Lasso
- Elastic Net

Alternativa de asignación directa (DFL):


$$w(x) = \text{softmax}(g_{\phi}(x))$$

Una red MLP entrenada para maximizar el Sharpe *sin pasar por μ* ni por Markowitz.

¹ S covarianza muestral, $F = mI$: diagonal con la varianza promedio m , δ parámetro que minimiza error de estimación

Cómo funciona el algoritmo propuesto

La cadena: ML predice, Markowitz optimiza



- El ML **refina un solo insumo**: el $\hat{\mu}$. No reemplaza a Markowitz.
- Markowitz **no predice**: es el optimizador que, dado $\hat{\mu}$ y $\hat{\Sigma}$, entrega los pesos.
- Todo dentro del walk-forward: en el mes t sólo se usan datos hasta $t - 1$.

Optimización de los modelos ML

Refinamiento: elegir hiperparámetros maximizando el Sharpe

Para cada modelo ML buscamos los hiperparámetros que dan **mejor Sharpe**, sin mirar el test.

Selección por Sharpe en validación interna


Dentro de cada ventana de 36 meses:

1. *inner-train*: primeros 24 meses.
2. *validación*: últimos 12 meses → se mide el Sharpe de la cartera.
3. se conserva el hiperparámetro de **mayor Sharpe en validación**.

Llamamos `_refine` a estas versiones.

Comparación entre modelos

Poder predictivo y Sharpe por modelo



Ningún modelo logra R^2_{oos} positiva: predicen peor que la media histórica. El Sharpe “bueno” viene del optimizador y la covarianza, no de la predicción.

Information Coefficient: Predicción vs. $1/N$

El IC de todos los modelos ronda el cero.
Ninguno logra *ordenar* ni distinguir qué
acción rendirá más que otra.

Conexión con el $1/N$: Si el IC es cero, no
hay información para distinguir entre
activos.

Cuadro 2: Poder predictivo

Modelo	IC
Ridge	+0.008
Lasso	+0.022
Elastic Net	+0.022
MLP	−0.013

*“...if there is no known reason for predicating
of our subject one rather than another of
several alternatives, then [...] the assertions of
each of these alternatives have an equal
probability.”*


— J.M. Keynes (1921) ¹¹

Desempeño de las estrategias

Estrategia	Sharpe	Max DD	Turnover
1/N	0.125	−40.7%	0.045
Markowitz	0.240	−37.9%	0.280
Markowitz+LW	0.238	−38.9%	0.275
MinVar+LW	0.080	−33.6%	0.141
ML Ridge+LW	0.296	−38.0%	0.677
DFL	0.046	−31.8%	1.102

El ML+LW lidera en Sharpe; el DFL (asignación directa) queda **último** en Sharpe (0.046) y con un *turnover* desproporcionado (1.10 vs. 0.045).

Valor de Cartera Acumulado



¿El refinamiento por Sharpe mejora?

Sharpe **base** (por MSE) vs. **_refine** (por Sharpe)

Modelo	base (MSE)	_refine (Sharpe)	Δ
Ridge	0.296	0.150	−0.146
Lasso	0.267	0.160	−0.107
Elastic Net	0.247	0.044	−0.203


No mejora

Afinar directamente por Sharpe **empeora** el desempeño fuera de muestra en los tres casos.

Bootstrap y conclusión

¿Las diferencias son reales o ruido?

Moving-block bootstrap (5000 réplicas, bloques de 6 meses): remuestreamos los retornos y reconstruimos la distribución del Sharpe de cada estrategia.



- Todos los intervalos de confianza al 95% **cruzan el cero**.
- Ninguna estrategia supera al 1/N de forma significativa: todos los $p \geq 0.23$.
- El mejor candidato (ML+LW) da $p = 0.234$; el mejor ML afinado (Lasso_refine), $p = 0.831$.

Conclusión

- Construimos modelos ML (predicción de μ y asignación directa), con selección de hiperparámetros por Sharpe **sin fuga**.
- **Ninguno supera al $1/N$ de forma estadísticamente distinguible**, y ninguno logra R^2_{oos} positiva.
- **IC ≈ 0** : El ML no distingue acciones buenas de malas. **Esta es la comparación directa contra el $1/N$** .
- El μ no es predecible en esta muestra $\Rightarrow$ la optimización basada en él no agrega valor sobre repartir en partes iguales y esto era un resultado esperado pues replicamos con acciones chilenas el trabajo de **DeMiguel, Garlappi & Uppal, 2009**.

¿Preguntas?

- Ridge: Para cada acción i ajusta coeficientes β_i que predican su retorno a partir de las *features*, penalizando la magnitud *cuadrática* de los coeficientes:

$$\hat{\beta}_i^{\text{Ridge}} = \arg \min_{\beta} \sum_t (r_{i,t} - \mathbf{x}_{i,t-1}^\top \beta)^2 + \alpha \sum_j \beta_j^2.$$

- Lasso: Misma idea que Ridge, cambiando la penalización cuadrática por una en valor absoluto:

$$\hat{\beta}_i^{\text{Lasso}} = \arg \min_{\beta} \sum_t (r_{i,t} - \mathbf{x}_{i,t-1}^\top \beta)^2 + \alpha \sum_j |\beta_j|.$$

- Elastic Net: Combina ambas penalizaciones con un parámetro de mezcla $\rho \in [0, 1]$:

$$\hat{\beta}_i^{\text{EN}} = \arg \min_{\beta} \sum_t (r_{i,t} - \mathbf{x}_{i,t-1}^\top \beta)^2 + \alpha \left[\rho \sum_j |\beta_j| + \frac{1-\rho}{2} \sum_j \beta_j^2 \right].$$

Regularización

Si un modelo tuviera señal real, la validación cruzada elegiría una regularización **estable** y **moderada**. Eso no es lo que ocurre:

Modelo	α modal	% en la moda	¿Tope de la grilla?
Ridge	10 000	56.0%	Sí
Lasso	0.1	82.2%	No
Elastic Net	0.1	86.6%	No
MLP	100	39.8%	Ambiguo

Ridge se va al extremo más regularizado incluso ampliando la grilla; Lasso y Elastic Net convergen a un valor *interior* (no de borde). En estos tres casos, la validación misma castiga cualquier intento de aprovechar las features: confirma la **ausencia de señal** sin depender del R^2_{oos} .

¿Por qué el DFL fracasó?

"El Decision-Focused Learning (DFL) optimiza el Sharpe directamente. ¿Por qué dio un resultado tan malo?"

Respuesta: Sobreajuste extremo por la topología del problema.

- Como la ventana de entrenamiento es corta (36 meses), la red encuentra "atajos" numéricos: pesos extremos que minimizan la varianza histórica pero que no tienen poder predictivo real.
- Evidencia: Su *Turnover* fue de 1.102 (compraba y vendía el 100% del portafolio cada mes). Fuera de muestra, esto destruye el retorno por costos de transacción y por pura varianza del ruido.

Conclusión del DFL

Maximizar una métrica no lineal (Sharpe) con gradientes sobre datos ruidosos sin señal predictiva ($IC \approx 0$) resulta en memorización, no en generalización.